无监督聚类的评价指标

评估聚类结果的质量与效果，是将不同算法和参数组合进行对比的核心环节。本节将介绍两种常用的指标：轮廓系数 (Silhouette Coefficient) 和 Davies-Bouldin 指数 (DBI)。

这些评估指标帮助我们量化“好”的标准，例如：紧凑性、分离度、稳定性以及实用性。这些指标通常基于数据点的距离或相似度来计算。

轮廓系数 (Silhouette Coefficient)

轮廓系数 (Silhouette Coefficient) 一般是衡量样本聚类结果的紧密程度的指标。它结合了类内平均距离和类间最小平均距离，取值范围：-1 到 1。值越大表示聚类效果越好。

公式：

$$s = \frac{b - a}{\max(a, b)}$$

其中，a 代表同一簇内样本点到其他点的平均距离（类内距离），b 代表样本点到最近其他簇的平均距离（最近类间距离）。

戴维斯-布尔丁指数 (Davies-Bouldin Index, DBI)

DBI 是一种通过计算类内紧密度与类间分离度的比值来进行评估的指标。DBI 值越小，表示聚类效果越好。

公式：

$$DBI = \frac{1}{N} \sum_{i=1}^{N} \max_{j \neq i} \left(\frac{\sigma_i + \sigma_j}{d(c_i, c_j)} \right)$$

其中，N 是簇的总数，σ_i 是簇 i 内所有点到其质心的平均距离，$d(c_i, c_j)$ 是簇 i 和簇 j 质心之间的距离。

实验设计

数据集选择：sklearn 的 make_blobs 函数，生成多个高斯分布的簇，用于测试算法在理想情况下的表现。

- 参数设置：固定样本数量，调整簇的数量 (n_clusters)。
- 算法对比：分别对 K-means 和 FCM 算法进行测试。
- 评估指标：记录每个算法在不同簇数下的轮廓系数和 DBI 值。

实验结果

- 轮廓系数 (Silhouette Coefficient)

- DBI 指数

代码实现说明

`plot_clustering_metrics.py`	主脚本，生成上图。
`fcm_sklearn.py`	模糊C-均值算法实现。
`requirements.txt`	依赖文件。
`.gitignore`	忽略文件。
`LICENSE`	MIT 许可证。
`README.zh.md`	中文项目说明。

- 轮廓系数 (Silhouette Coefficient)：衡量样本聚类结果的紧密程度，取值范围 [-1, 1]，值越大表示聚类效果越好。
- 戴维斯-布尔丁指数 (DBI)：通过比较类内紧密度与类间分离度的比值来进行评估，值越小表示聚类效果越好。
- 实验设计：使用 sklearn 的 make_blobs 生成数据，固定样本数量，调整簇的数量 (n_clusters)，分别对 K-means 和 FCM 算法进行测试，记录不同簇数下的轮廓系数和 DBI 值。
- 结果：生成的图表清晰地展示了两种算法在不同簇数下的表现，为选择合适的算法和参数提供了依据。

代码实现说明

`plot_clustering_metrics.py`	主脚本，生成上图。
`fcm_sklearn.py`	模糊C-均值算法实现。
`requirements.txt`	依赖文件。
`.gitignore`	忽略文件。
`LICENSE`	MIT 许可证。
`README.zh.md`	中文项目说明。

代码实现

数据集选择

- 使用 sklearn 的 make_blobs 函数，生成多个高斯分布的簇，用于测试算法在理想情况下的表现。
- 参数设置：固定样本数量，调整簇的数量 (n_clusters)。

算法实现

- K-means：使用 sklearn 的 KMeans 类。
- FCM：使用自定义的 FuzzyCMeans 类，基于 scikit-learn 的 BaseEstimator 和 ClusterMixin 接口实现。

评估与可视化

- 计算轮廓系数 (Silhouette Coefficient) 和 Davies-Bouldin 指数 (DBI)。
- 使用 matplotlib 和 seaborn 绘制结果图表，清晰地展示不同算法在不同簇数下的表现。

结果分析

- 轮廓系数：通常在簇数接近真实值时达到峰值，表明聚类效果最佳。
- DBI 指数：通常在簇数接近真实值时达到谷底，表明聚类效果最佳。
- 算法对比：通过图表可以清晰地看出 K-means 和 FCM 在不同数据集上的表现差异，为实际应用中选择合适的算法提供参考。

结论

- 无监督聚类评估指标：轮廓系数和 DBI 指数是常用的无监督聚类评估指标，能够在没有真实标签的情况下，对聚类效果进行有效的量化评估。
- 算法选择：不同的聚类算法在不同的数据集上表现可能存在差异，需要根据具体情况进行测试和选择。
- 参数调优：聚类算法的参数（如簇数）对结果有显著影响，需要通过实验来寻找最优参数。

代码实现说明

`plot_clustering_metrics.py`	主脚本，生成上图。
`fcm_sklearn.py`	模糊C-均值算法实现。
`requirements.txt`	依赖文件。
`.gitignore`	忽略文件。
`LICENSE`	MIT 许可证。
`README.zh.md`	中文项目说明。

结论

- 无监督聚类评估指标：轮廓系数和 DBI 指数是常用的无监督聚类评估指标，能够在没有真实标签的情况下，对聚类效果进行有效的量化评估。
- 算法选择：不同的聚类算法在不同的数据集上表现可能存在差异，需要根据具体情况进行测试和选择。
- 参数调优：聚类算法的参数（如簇数）对结果有显著影响，需要通过实验来寻找最优参数。

参考资料

- 轮廓系数维基百科：https://zh.wikipedia.org/wiki/%E7%BB%BD%E5%BD%A2%E7%B3%BB%E6%95%B0
- https://github.com/fdbf/fuzzy-c-means/blob/master/examples/iris/README.md